

4. Sandbox API

AlfaGen

28 July, 2026

Table of Contents

1	Условия использования API Sandbox.....	4
2	Доступные модели*	5
3	Сравнение Sandbox API и AlfaGen API*.....	6
4	Инструкция по подключению к Sandbox API	7
5	Шаг 1. Получение доступа к Sandbox API	8
6	Шаг 2. Подключение к Sandbox API	9
7	Шаг 3. Запрос на продление доступа.....	10
8	Описание методов	11
9	Инструкция по использованию AlfaGen API	12
9.1	Коллекция для Postman с примерами запросов	12
9.2	Structured Output.....	12
9.3	Использование Tools в запросах.....	13
9.4	Работа с файлами.....	18
9.5	Предобработка запроса через Autotune [Beta]	23
9.6	LLM Tokenizer (Tokenize/Detokenize).....	25
9.7	Streaming ответов.....	33
10	Отсутствует сетевой доступ.....	38
11	Если вы столкнулись с некорректной работой Sandbox API	40

Sandbox API - это демо-инструмент для взаимодействия с GenAI моделями, который выдается пользователям на 3 месяца для проверки гипотез. Сетевой доступ к Sandbox API открыт только с IP-адресах сотрудников из VPN и VDI. Целевой инструмент для интеграций систем с GenAI моделями - [AlfaGen API](#)¹.



Задать вопросы по работе Sandbox API, рассказать о проблеме или предложить feature request можно в чате AlfaGen Club (внутренний чат "Sandbox API"): [в контуре банка](#)² и [вне контура](#).³



Sandbox API работает **только на IP-адресах сотрудников из VPN и VDI** (интеграция пользователь-система). Если вам нужен доступ из системы - воспользуйтесь AlfaGen API Test [Инструкция по подключению к LLM](#)⁴



Sandbox API содержит **ограниченный функционал по сравнению с AlfaGen API Test**. Часть запросов может отклоняться из-за наличия подозрений на чувствительную информацию в запросе. Как подключиться к AlfaGen API - [Инструкция по подключению к LLM](#)⁵

1. <https://confluence.moscow.alfaintra.net/spaces/GPT/pages/2364080887/%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F+%D0%BF%D0%BE+%D0%BF%D0%BE%D0%B4%D0%BA%D0%BB%D1%8E%D1%87%D0%B5%D0%BD%D0%B8%D1%8E+%D0%BA+LLM>
2. <https://ap.moscow.alfaintra.net/channels/?inviteId=171>
3. <https://alfapeople.alfabank.ru/channels/?inviteId=171>
4. <https://confluence.moscow.alfaintra.net/spaces/GPT/pages/2364080887/%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F+%D0%BF%D0%BE+%D0%BF%D0%BE%D0%B4%D0%BA%D0%BB%D1%8E%D1%87%D0%B5%D0%BD%D0%B8%D1%8E+%D0%BA+LLM>
5. <https://confluence.moscow.alfaintra.net/spaces/GPT/pages/2364080887/%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F+%D0%BF%D0%BE+%D0%BF%D0%BE%D0%B4%D0%BA%D0%BB%D1%8E%D1%87%D0%B5%D0%BD%D0%B8%D1%8E+%D0%BA+LLM>

1 Условия использования API Sandbox

Ограничения:

- Нагрузка: **не более 0,2 RPS**
- Вы не сможете подключиться к Sandbox из системы в Production. **Работа с Sandbox возможна исключительно через IP-адреса VPN и VDI.**
- Срок доступа: **3 месяца.**

2 Доступные модели*

Имя модели	Описание	Request Max Tokens	Комментарий
Qwen/QwQ-32B	Ризонинг модель	40 954	
gpt-oss-120b	Обычная модель	131 066	
/models/llama-3.3	Обычная модель	31 994	
Qwen/Qwen3-Coder-Next	Ризонинг модель	209 715	new, ready to work
Qwen/Qwen3.6-35B-A3B-FP8	Мультимодальная модель, можно использовать с картинками	209 715	new, ready to work
Qwen/Qwen3.5-122B-A10B-FP8	Ризонинг модель	160 000	new, coming soon
google/gemma-4-26B-A4B-it	Ризонинг модель	209 715	new, coming soon
openai/t-tech/T-pro-it-2.1-FP8	Ризонинг модель	26 214	new, coming soon
PaddlePaddle/PaddleOCR-VL-1.6	Обычная модель	104 857	new, coming soon
deepseek-ai/DeepSeek-V4-Flash	Ризонинг модель	800 000	new, coming soon
BAAI/bge-m3	Эмбеddинг модель	-	new, coming soon

*Перечисленные модели открыты на всех пользователей Sandbox API. Выделенные модели под определенного пользователя добавить в Sandbox API не сможем, вместо этого есть AlfaGen API (как подключиться к AlfaGen API - [Инструкция по подключению к LLM⁶](#))

6. <https://confluence.moscow.alfaintra.net/spaces/GPT/pages/2364080887/%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F+%D0%BF%D0%BE+%D0%BF%D0%BE%D0%B4%D0%BA%D0%BB%D1%8E%D1%87%D0%B5%D0%BD%D0%B8%D1%8E+%D0%BA+LLM>

3 Сравнение Sandbox API и AlfaGen API*

Sandbox API и AlfaGen API - 2 разных продукта с разным назначением.

Параметр	Sandbox API	AlfaGen API
Назначение	Тестирование гипотез и проведение экспериментов перед переходом в AlfaGen API	Целевая интеграция продукта с Generative AI моделями в Production
Среда AlfaGen	Тест	Тест, Прод
Тип интеграции	Пользователь-система	Система-система
Требуемая документация	Нет	Vision для теста, РИ для прода
Необходимость согласовывать GPU	Нет	Да
Максимальный RPS	0,2 RPS	Зависит от модели (может быть неограничен)
Срок доступа	3 месяца	Не ограничен

*Инструкция по подключению к AlfaGen API - [Инструкция по подключению к LLM](#)⁷

7. <https://confluence.moscow.alfaintra.net/spaces/GPT/pages/2364080887/%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F+%D0%BF%D0%BE+%D0%BF%D0%BE%D0%B4%D0%BA%D0%BB%D1%8E%D1%87%D0%B5%D0%BD%D0%B8%D1%8E+%D0%BA+LLM>

4 Инструкция по подключению к Sandbox API

5 Шаг 1. Получение доступа к Sandbox API

Действия:

1. Напишите письмо на адрес: EYanovskaya@alfabank.ru⁸
 - **Тема письма:**
Получение доступа к Sandbox (ФИО пользователя)
Пример: «Получение доступа к Sandbox (Иванов Иван Иванович)». Просим придерживаться формату, иначе письмо не пройдет фильтр
1. В тексте письма:
 - Приложите **заполненную анкету** - [Анкета АльфаГен Доступ к API.xlsx](#)⁹
 - Если просите добавить вашего коллегу, то укажите также его почту, пожалуйста (чтобы мы добавили его в рассылку при важных изменениях API).
2. **Дождитесь ответа:**
 - В ответном письме вы получите **авторизационный ключ** в формате UUID, необходимый для подключения к Sandbox API.
 - 💡 Срок на выдачу ключей в sandbox - 2 рабочих дня
 - ⚠️ Обращаем ваше внимание, что **авторизационный ключ** предназначен для отправки запросов через Postman и т.д. Доступ к Sandbox из браузера не производится.

Примечание:

- Доступ предоставляется только сотрудникам банка.
- Срок обработки запроса зависит от текущей загрузки команды (обычно до 2 рабочих дней).

8. <mailto:EYanovskaya@alfabank.ru>

9. <https://confluence.moscow.alfaintra.net/download/attachments/2429161034/%D0%90%D0%BD%D0%BA%D0%B5%D1%82%D0%B0%20%D0%90%D0%BB%D1%8C%D1%84%D0%B0%D0%93%D0%B5%D0%BD%20%D0%94%D0%BE%D1%81%D1%82%D1%83%D0%BF%20%D0%BA%20API.xlsx?api=v2&modificationDate=1754573543000&version=2>

6 Шаг 2. Подключение к Sandbox API

systemId - **sanduser**

Token - **получаете по почте**

messageId - не обязательный параметр, но помогающий идентифицировать ваш запрос в будущем по логам.

7 Шаг 3. Запрос на продление доступа

Действия:

1. Напишите письмо на адрес: EYanovskaya@alfabank.ru¹⁰
 - a. Тема письма:
 - i. Получение доступа к Sandbox (ФИО пользователя)
Пример: «Получение доступа к Sandbox (Иванов Иван Иванович)»
 - b. В тексте письма:
 - i. Укажите, что требуется продление ранее выданного доступа
 - ii. При необходимости приложите обновлённую анкету: [Анкета АльфаГен Доступ к API.xlsx](#)¹¹
 - iii. Если требуется продление для других пользователей, укажите их email
 - c. Дождитесь ответа:
 - i. В ответном письме вы получите **подтверждение о продлении ключа**
 - ii. 🕒 Срок на выдачу ключей в sandbox - 2 рабочих дня
 - iii. ⚠️ Обращаем ваше внимание, что **авторизационный ключ** предназначен для отправки запросов через Postman и т.д. Доступ к Sandbox из браузере не производится.

Срок обработки:
До 2 рабочих дней

10. <mailto:EYanovskaya@alfabank.ru>

11. <https://confluence.moscow.alfaintra.net/download/attachments/2429161034/%D0%90%D0%BD%D0%BA%D0%B5%D1%82%D0%B0%20%D0%90%D0%BB%D1%8C%D1%84%D0%B0%D0%93%D0%B5%D0%BD%20%D0%94%D0%BE%D1%81%D1%82%D1%83%D0%BF%20%D0%BA%20API.xlsx?api=v2&modificationDate=1754573543000&version=2>

8 Описание методов



Описание методов ниже может содержать неактуальные Example Value и коды ошибок. Просим ориентироваться на примеры в "**Инструкция по использованию AlfaGen API**" и ошибки в "**Описание возможных ошибок**".




Использование функциональности, не описанной в текущей документации, запрещено. При выявлении таких запросов система-пользователь может быть забанена.

9 Инструкция по использованию AlfaGen API

9.1 Коллекция для Postman с примерами запросов

Коллекция для Postman с примерами запросов



9.2 Structured Output

Structured output

Функционал structured output позволяет задать формат, в котором модель должна вернуть ответ.

Пример запроса	Особенности
<pre> { "messages": [{ "content": "Вы — помощник, который всегда отвечает в формате JSON.", "role": "system" }, { "content": "Меня зовут Иван, мне 30 лет. Верни в json формате сколько мне лет и как меня зовут", "role": "user" }], "model": "Qwen/QwQ-32B", "n": 1, "temperature": 0.2, "response_format": { "type": "json_schema", "json_schema": { "strict": true, "name": "Test_schema", "schema": { "\$id": "https://example.com/ address.schema.json", "\$schema": "https://json-schema.org/draft/ 2020-12/schema", "description": "Схема предназначена для извлечение информации об имени и возрасте человека в формате JSON", "type": "object", "properties": { "name": { "type": "string" }, "age": { "type": "string" } }, "required": ["name", "age"] } } }, "max_completion_tokens": 500 } </pre>	• Рекомендуется дополнительно указывать формат в промпте • Модели с функцией рассуждения могут вернуть текст рассуждения не в заданном формате • Функционал может не работать на некоторых версиях TGI инференса • При описании схемы все атрибуты должны быть указаны как required

9.3 Использование Tools в запросах

Tools

Функционал tools позволяет передавать модели информацию о функции, с помощью которой можно добавить дополнительную информацию в модель для более точного ответа.

Ниже приведен пример для процесса получения информации о покупке валюты. Модель может не знать текущий курс, поэтому информацию о текущем курсе нужно передать вместе с промптом. Если у вас есть функция, которая умеет получать курсы валют, то модель может вернуть в ответе аргументы для функции. После вызова функции с нужными аргументами, информацию о курсе можно передать в модель.

Функционал tools работает с моделями **Qwen/QwQ-32B**, **/models/llama-3.3**, **gpt-oss-120b**.

	Пример	Комментарии
1	Пример запроса с указанием функций, по которым модель вернет аргументы. <pre> { "messages": [{ "role": "user", "content": "Сколько стоит 100 долларов в рублях?" }], "tools": [{ "type": "function", "function": { "name": "get_exchange_rate", "description": "Возвращает текущий курс валюты", "strict": true, "parameters": { "type": "object", "properties": { "from": { "type": "string", "example": "USD" }, "to": { "type": "string", "example": "RUB" } }, "required": ["from", "to"] } } }], "tool_choice": "auto", "model": "gpt-oss-120b" } </pre>	От пользователя есть вопрос - сколько стоит 100 долларов в рублях. Система-клиент вместе с запросом пользователя передает массив tools. В массиве tools передаются функции, которые модель может использовать для ответа. Обратите внимание, что сама модель не вызывает указанную функцию, она лишь возвращает аргументы, которые вы можете передать в свою функцию. ВАЖНО Атрибут tools.function.strict не является обязательным для большинства моделей, но некоторые модели могут некорректно работать без него (например, gpt-oss-120b), поэтому мы рекомендуем в явном виде задавать этот атрибут в запросе. tool_choice позволяет задать поведение модели относительно tools. • auto - модель решает, ответить ли самостоятельно или вернуть аргументы для функции • none - модель обязана ответить самостоятельно и не возвращать аргументы для функции • required - модель обязана вернуть аргументы для одной или нескольких функций, а не отвечать самостоятельно

	Пример	Комментарии
2	Ответ от модели на запрос из п.1 <pre>{ "id": "0c5fde4ac4a54e19a5a7f739761cf097", "object": "chat.completion", "created": 1758278448, "model": "gpt-oss-120b", "choices": [{ "index": 0, "message": { "role": "assistant", "content": "", "tool_calls": [{ "id": "call_ec8d6fe85928482596c54b59", "function": { "name": "get_exchange_rate", "arguments": "{\n\"from\":\n\n\"USD\", \"to\": \"RUB\"}" }, "type": "function" }] }, "logprobs": null, "finish_reason": "tool_calls" }], "usage": { "prompt_tokens": 137, "completion_tokens": 65, "total_tokens": 202 } }</pre>	В данном случае модель вернула аргументы для функции Вам необходимо передать эти аргументы в свою функцию, а ответ от функции передать в модель (см.п.3)


	Пример	Комментарии
3	Запрос с результатом выполнения функции <pre> { "model": "gpt-oss-120b", "messages": [{ "role": "user", "content": "Сколько стоит 100 долларов в рублях?" }, { "role": "assistant", "content": "", "tool_calls": [{ "id": "call_ec8d6fe85928482596 c54b59", "function": { "name": "get_exchange_rate", "arguments": "{\"from\": \"USD\", \"to\": \"RUB\"}" }, "type": "function" }] }], { "role": "tool", "name": "get_exchange_rate", "content": "\"rate\": 999" }] } </pre>	В запрос передается история сообщений - в том числе, сообщение пользователя и ответ от LLM. Последним передается сообщение с ролью tools, где указывается результат выполнения функции. В данном случае мы передаем, что курс равен 999.

	Пример	Комментарии
4	Человекочитаемый ответ от модели на запрос из п.3 <pre>{ "id": "9c065d2de76741fc8260068c5a37c62e", "object": "chat.completion", "created": 1758282696, "model": "gpt-oss-120b", "choices": [{ "index": 0, "message": { "role": "assistant", "content": "100 USD ≈ 100 × 999 RUB = 99 900 RUB. \n\nКурс валют меняется, поэтому для точного расчёта лучше проверить актуальный курс в банке или на финансовом сайте.", "tool_calls": [], "logprobs": null, "finish_reason": "stop" } }, "usage": { "prompt_tokens": 124, "completion_tokens": 142, "total_tokens": 266 }] }</pre>	Модель проанализировала запрос пользователя, функцию, для которой она передавала аргументы ранее и ответ от функции. На основании этих данных модель выводит человекочитаемый ответ.

9.4 Работа с файлами

Работа с файлами

Видео-инструкция:



Для каких файлов подходит	Необходимые шаги
Допустимые форматы: doc, docx, pdf, csv, xls, xlsx, jpeg, jpg, png, rtf, ppt, pptx, md, txt, json Допустимый размер: до 15мб	1. Загрузить файл через POST /upload-file, получить id загрузки. 2. Через GET /sse получить status = COMPLETED и id загруженного файла (в path запроса указывается id = id загрузки из ответа на запрос POST /upload-file). 3. Полученный id загруженного файла указать в запросе POST /chat/completions в messages.content.file_id (messages.role = user, messages.content.type = file). TTL на загруженные файлы - 1д. ⚠ Sandbox API не гарантирует, что TTL будет всегда 1 день.

*Обработка текстовых файлов доступна для любых моделей, обработка изображений - только для vl-модели qwen-2.5-32b-vl.

⚠

Файл помещается в хранилище только при успешном прохождении всех проверок:

1. Валидация по расширению файла - проверяем, что ФПС поддерживает присланное расширение файла
2. Валидация по размеру - проверка на допустимый размер файла.
3. Проверка на mimeType - для загружаемого файла указан mimeType, который сервис ожидает
4. Проверка формата имени файла - в имени файла обязательно должно быть указано расширение после «.» Например, «Проверка.pdf»
5. Проверка на соответствие первых байтов присланного файла поддерживаемым байтам для указанного расширения файла

	Пример	Комментарии
1	POST v1/upload-file Запрос <pre>curl --location 'http:// {{sandbox_URL}}/ internal/llm/v1/ upload-file' \ --header 'systemId: assistant' \ --header 'messageId: test-message-id' \ --header 'Authorization: Bearer token' \ --form 'file=@"/ Users/askarshakurov/ Downloads/0mb.md"'</pre> Ответ <pre>{ }</pre>	Пример запроса на загрузку файла. В ответе придет id загрузки.

	Пример	Комментарии
2	GET v1/upload-file/{{id}}/sse Запрос <pre>curl --location 'http:// {{sandbox_URL}}/ internal/llm/v1/ upload-file/{{id}}/ sse' \ --header 'systemId: assistant' \ --header 'messageId: test-message-id' \ --header 'Authorization: Bearer token'</pre> Ответ <pre>{ }</pre>	Пример запроса на проверку статуса загруженного файла. В ответе придет status = COMPLETED и id загруженного файла

	Пример	Комментарии
3	POST v1/chat/completions Запрос <pre>curl --location 'http:// {{sandbox_URL}}/ internal/llm/v1/ chat/completions' \ --header 'systemId: assistant' \ --header 'messageId: test-message-id' \ --header 'Content- Type: application/ json' \ --header 'Authorization: Bearer token' \ --data '{ "model": "qwen-2.5-32b-v1", "n": 1, "messages": [{ "role": "user", "content": [{ "type": "text", "text": "Какой цвет изображен на фото?" }, { "type": "file", "file": { "file_id": "b5617c16-3f63-4c66- b51e-bf7be3d13b57" } }] }] }'</pre>	Пример запроса к модели с использованием загруженного файла.

	Пример	Комментарии
	Ответ { }	

9.5 Предобработка запроса через Autotune [Beta]

Предобработка запроса через Autotune [Beta]



- Параметр `autotune` доступен в методах **POST v1/completions** и **POST v1/chat/completions**

Логика работы:

- Если `autotune = true`, то вместо одного запроса к LLM, выполняется два:
 - a. предварительный системный запрос к LLM для уточнения у LLM оптимальных параметров для промпта пользователя:
 - i. `temperature` - температура для управления случайностью генерации
 - ii. `top_p` - Альтернатива выборке с температурой, называемая nucleus sampling, где модель рассматривает результаты токенов с вероятностной массой `top_p`
 - iii. `frequency_penalty` - штрафует токены, которые уже встречались в сгенерированном тексте. Чем чаще токен появляется, тем сильнее штраф. Актуально для следующих моделей: DeepSeek-R1, Qwen/Qwen2.5-Coder-32B-Instruct, qwen_tuned. Другие модели могут не поддерживать этот атрибут.
 - iv. `presence_penalty` - положительные значения штрафуют новые токены на основе того, появляются ли они в тексте до сих пор, увеличивая вероятность модели говорить о новых темах.
 - b. основной запрос к LLM с промптом пользователя и с параметрами, которые подобрала LLM.
- Если `autotune = false` или не задан, то запрос к модели будет выполняться с указанными/неуказанными пользователем параметрами.
- В рамках MVP работа с сессией не реализована
- В **POST v1/completions** для подбора оптимальных параметров (автотюна) в LLM передается промпт

- В **POST v1/chat/completions** для автотюна в LLM передается последнее сообщение чата



Время ответа при autotune = true увеличивается, так как фактически выполняется 2 запроса к LLM

Пример	
1	POST v1/chat/completions Запрос <pre>{ "model": "/models/llama-3.3", "messages": [{ "content": "Отвечай как доктор биологических наук", "role": "system" }, { "content": "Есть ли у пингвина колени?", "role": "user" }], "autotune": true }</pre>
2	POST v1/completions Запрос <pre>{ "model": "/models/llama-3.3", "prompt": "Есть ли у пингвина колени?", "autotune": true }</pre>

9.6 LLM Tokenizer (Tokenize/Detokenize)

LLM Tokenizer (Tokenize/Detokenize)



Работает только для инференса vLLM.

В поле "model" нужно передавать название, как в инференсе.

Поддерживаемые модели:

Sandbox
llama-3.1-8b-instruct

Функциональность tokenize/detokenize позволяет переводить текст в токены (и токены в текст) с использованием стандартного токенизатора в инференсе ИИ модели.

Условие положительного ответа: инференс модели, к которой обращаются поддерживает стандартные методы tokenize/detokenize.

Ниже приведены примеры.

Пример		Комментарии
1	Перевод текста в токены Запрос <pre>{ "model": "llama-3.1-8b-instruct", "prompt": "Hello world", "add_special_tokens": false }</pre> Ответ <pre>{"count": 2, "max_model_len": 131072, "tokens": [9906, 1917], "token_strs": null }</pre>	<i>add_special_tokens</i> - Параметр, который определяет, добавлять ли специальные токены при переводе текста в токены. Полезен, когда нужно добавлять токены начала строки (bos token) и токены конца строки(eos token) автоматически.  Можно задать только один из 2х параметров - prompt или msg

	Пример	Комментарии
2	Перевод токенов в текст Запрос <pre>{ "model": "llama-3. 1-8b- instruct", "tokens": [9906,1917] }</pre> Ответ <pre>{ "prompt": "Hello world" }</pre>	

	Пример	Комментарии
3	Перевод текста в токены с учетом спец символов Запрос <pre>{ "model": "llama-3.1-8b-instruct", "prompt": "Привет! Как дела?", "add_special_tokens": false, "add_generation_prompt": false, "continue_final_message": false}</pre> Ответ <pre>{ "count": 7, "max_model_len": 131072, "tokens": [54745, 28089, 8341, 0, 107234, 123936, 30], "token_strs": null}</pre>	✖ Можно задать только один из 2х параметров - prompt или msg

	Пример	Комментарии
4	Перевод токенов в текст с учетом спец символов Запрос <pre>{ "model": "llama-3.1-8b-instruct", "tokens": [128000, 9906, 1917, 9468, 97, 234] }</pre> Ответ <pre>{ "prompt": "< begin_of_text >Hello world 🍌" }</pre>	< begin_of_text > - спецсимвол начала строки

Пример	Комментарии
5 Перевод текста в токены для чат-сообщений Запрос <pre>{ "model": "llama-3.1-8b-instruct", "messages": [{ "role": "user", "content": "Как дела?" }, { "role": "user", "content": "Как дела?" }], "add_special_tokens": false, "add_generation_prompt": false, "continue_final_message": false }</pre> Ответ <pre>{ "count": 42, "max_model_len": 131072, "tokens": [128000, 128006, 9125, 128007, 271, </pre>	<code>add_generation_prompt</code> - Описание на HuggingFace¹² - Параметр работает только для чата. Когда параметр <code>add_generation_prompt = true</code>, в конец чата добавляется специальный токен, который означает начало ответа ассистента. Не все модели требуют <code>generation prompts</code>. Некоторые модели, например Llama не имеют специальных токенов перед ответом ассистента. В этих случаях <code>add_generation_prompt</code> не будет давать эффекта. add_generation_prompt = true <pre>tokenized_chat = tokenizer.apply_chat_template(messages, tokenize=False, add_generation_prompt=True) tokenized_chat < im_start >user Hi there!< im_end > < im_start >assistant Nice to meet you!< im_end > < im_start >user Can I ask a question?< im_end > < im_start >assistant</pre> add_generation_prompt = false <pre>tokenized_chat = tokenizer.apply_chat_template(messages, tokenize=False, add_generation_prompt=False) tokenized_chat < im_start >user Hi there!< im_end > < im_start >assistant Nice to meet you!< im_end > < im_start >user Can I ask a question?< im_end ></pre> <code>continue_final_message</code> - (Описание на HuggingFace)¹³ - Параметр работает только для чата. Параметр <code>continue_final_message</code>¹⁴ контролирует, должно ли последнее сообщение в чате быть продолжено или нет (вместо начала нового сообщения). Параметр удаляет конечную последовательность токенов, так чтобы модель продолжила генерацию ответа с последнего сообщения. Это полезно для "предзаполнения" ответа модели.

12. https://huggingface.co/docs/transformers/main/chat_templating#addgenerationprompt

13. https://huggingface.co/docs/transformers/main/chat_templating#continuefinalmessage

14. https://huggingface.co/docs/transformers/internal/tokenization_utils#transformers.PreTrainedTokenizerBase.apply_chat_template.continue_final_message

Пример	Комментарии
<pre> 38766, 1303, 33025, 2696, 25, 6790, 220, 2366, 18, 198, 15724, 2696, 25, 220, 1627, 10263, 220, 2366, 19, 271, 128009, 128006, 882, 128007, 271, 106523, 123936, 30, 128009, 128006, 882, 128007, 271, 106523, 123936, 30, 128009], "token_strs": null } </pre>	 Нельзя использовать add_generation_prompt¹⁵ и continue_final_message¹⁶ вместе. первый добавляет токены для начала нового сообщения, а второй удаляет токены конца сообщения. Если установить add_generation_prompt¹⁷ = true и continue_final_message¹⁸ = true, то инференс вернет ошибку.  Можно задать только один из 2х параметров - prompt или msg

15. https://huggingface.co/docs/transformers/internal/tokenization_utils#transformers.PreTrainedTokenizerBase.apply_chat_template.add_generation_prompt

16. https://huggingface.co/docs/transformers/internal/tokenization_utils#transformers.PreTrainedTokenizerBase.apply_chat_template.continue_final_message

17. https://huggingface.co/docs/transformers/internal/tokenization_utils#transformers.PreTrainedTokenizerBase.apply_chat_template.add_generation_prompt

18. https://huggingface.co/docs/transformers/internal/tokenization_utils#transformers.PreTrainedTokenizerBase.apply_chat_template.continue_final_message

Пример		Комментарии
6	Перевод токенов в текст для чат-сообщений	
	Запрос	
	<pre>{ "model": "llama-3.1-8b-instruct", "tokens": [128000, 128006, 9125, 128007, 271, 38766, 1303, 33025, 2696, 25, 6790, 220, 2366, 18, 198, 15724, 2696, 25, 220, 1627, 10263, 220, 2366, 19, 271, 128009, 128006, 882, 128007, 271, 106523, 123936, 30, 128009, 128006, 882, 128007, 271, 106523, 123936, 30, 128009] }</pre>	

Пример	Комментарии
<pre>] }</pre> Ответ <pre>{ "prompt": "< begin_of_text >< start_header_id >system< end_header_id >\n\nCutting Knowledge Date: December 2023\nToday Date: 26 Jul 2024\n\n< eot_id >< start_header_id >user< end_header_id >\n\nКак дела?< eot_id >< start_header_id >user< end_header_id >\n\nКак дела?< eot_id >" }</pre>	

9.7 Streaming ответов

Stream

Функционал stream позволяет получать ответ от модели в режиме реального времени по частям (Server-Sent Events), не дожидаясь завершения генерации целиком.



Важно

Чтобы включить режим stream, необходимо передать параметр `stream: true` в теле запроса.

Ответ возвращается в формате `text/event-stream`: каждый чанк — отдельная строка вида `data: {...}`.

Поток завершается специальным сообщением `data: [DONE]`.

В режиме stream поле `usage` в промежуточных чанках отсутствует — оно возвращается только в последнем чанке перед `[DONE]`.

Примеры запросов и ответов	Комментарии
stream: true Запрос <pre>curl --request POST \ --url https://agenapisandbox.moscow.alfaintra.net/ internal/llm/v1/chat/completions \ --header 'authorization: Bearer 47c763f2- a12e-44b5-8f70-6da843afe07a' \ --header 'content-type: application/json' \ --header 'messageid: 0f3c43da-d4b2-4a19- b122-39aae04946e0' \ --header 'systemid: sanduser' \ --data '{ "model": "Qwen/Qwen3-Coder-Next", "stream": true, "messages": [{ "role": "system", "content": "как дела?" }] }'</pre> Ответ <pre>data: {"id":"33a3d283804a4904b08503ca0586c026","object":"ch at.completion.chunk","created":1783579194,"model":"Qw en/Qwen3-Coder-Next","choices":[{"index":0,"delta": {"role":"assistant","content":"","tool_calls": []},"logprobs":null}]} 2026-07-09T06:39:54.133Z data: {"id":"33a3d283804a4904b08503ca0586c026","object":"ch at.completion.chunk","created":1783579194,"model":"Qw en/Qwen3-Coder-Next","choices":[{"index":0,"delta": {"role":null,"content":"Пп","tool_calls": []},"logprobs":null}]} data: {"id":"33a3d283804a4904b08503ca0586c026","object":"ch at.completion.chunk","created":1783579194,"model":"Qw en/Qwen3-Coder-Next","choices":[{"index":0,"delta": {"role":null,"content":"ив","tool_calls": []},"logprobs":null}]} }</pre>	Каждый чанк содержит объект с полем <code>delta</code> – прирост текста. Первый чанк: <code>delta.role = "assistant"</code>, <code>delta.content = ""</code>. Промежуточные чанки: <code>delta.content</code> содержит очередной фрагмент текста, <code>finish_reason: null</code>. Последний чанк перед <code>[DONE]</code>: <code>finish_reason: "stop" или "length"</code>, содержит <code>usage</code>. Финальное сообщение: <code>data: [DONE]</code> – поток завершён.

Примеры запросов и ответов	Комментарии
<pre> data: {"id":"33a3d283804a4904b08503ca0586c026","object":"chat.completion.chunk","created":1783579194,"model":"Qwen/Qwen3-Coder-Next","choices":[{"index":0,"delta":{"role":null,"content":"et","tool_calls":[]},"logprobs":null}]} data: {"id":"33a3d283804a4904b08503ca0586c026","object":"chat.completion.chunk","created":1783579194,"model":"Qwen/Qwen3-Coder-Next","choices":[{"index":0,"delta":{"role":null,"content":"!", "tool_calls":[]},"logprobs":null}]} data: {"id":"33a3d283804a4904b08503ca0586c026","object":"chat.completion.chunk","created":1783579194,"model":"Qwen/Qwen3-Coder-Next","choices":[{"index":0,"delta":{"role":null,"content":" ", "tool_calls":[]},"logprobs":null}]} data: {"id":"33a3d283804a4904b08503ca0586c026","object":"chat.completion.chunk","created":1783579194,"model":"Qwen/Qwen3-Coder-Next","choices":[{"index":0,"delta":{"role":null,"content":"👉", "tool_calls":[]},"logprobs":null}]} data: {"id":"33a3d283804a4904b08503ca0586c026","object":"chat.completion.chunk","created":1783579194,"model":"Qwen/Qwen3-Coder-Next","choices":[{"index":0,"delta":{"role":null,"content":" B", "tool_calls":[]},"logprobs":null}]} 2026-07-09T06:39:54.144Z data: {"id":"33a3d283804a4904b08503ca0586c026","object":"chat.completion.chunk","created":1783579194,"model":"Qwen/Qwen3-Coder-Next","choices":[{"index":0,"delta":{"role":null,"content":"c", "tool_calls":[]},"logprobs":null}]} 2026-07-09T06:39:54.145Z ... </pre>	

Примеры запросов и ответов	Комментарии
stream: false (по умолчанию) Запрос <pre data-bbox="293 546 975 1106">curl --request POST \ --url https://agenapisandbox.moscow.alfaintra.net/ internal/llm/v1/chat/completions \ --header 'authorization: Bearer 47c763f2- a12e-44b5-8f70-6da843afe07a' \ --header 'content-type: application/json' \ --header 'messageid: 0f3c43da-d4b2-4a19- b122-39aae04946e0' \ --header 'systemid: sanduser' \ --data '{ "model": "Qwen/Qwen3-Coder-Next", "stream": false, "messages": [{ "role": "system", "content": "как дела?" }] }'</pre> Ответ <pre data-bbox="293 1317 975 1939">{ "id": "3d68b719ce2a4ece94da10b3cf3b30a4", "object": "chat.completion", "created": 1783579244, "model": "Qwen/Qwen3-Coder-Next", "choices": [{ "index": 0, "message": { "role": "assistant", "content": "Привет! 🙌 Всё отлично – у меня как раз и бывает, когда я помогаю людям решать задачи, улучшать код или просто обсуждать интересные темы 😊 \nА как у тебя дела? Чем могу помочь?", "tool_calls": [] }, "logprobs": null, "finish_reason": "stop" }], "usage": {</pre>	При <code>stream: false</code> (значение по умолчанию) ответ возвращается одним полным JSON-объектом после завершения генерации. <code>usage</code> присутствует в теле ответа.

	Примеры запросов и ответов	Комментарии
	<pre data-bbox="261 331 1026 517"> "prompt_tokens": 12, "completion_tokens": 63, "total_tokens": 75 } }</pre>	

10 Отсутствует сетевой доступ



Sandbox API работает только на IP-адресах сотрудников из VPN и VDI. Если вам нужен доступ из системы - воспользуйтесь AlfaGen API Test [Инструкция по подключению к LLM](#)¹⁹


Если запросы падают по тайм-ауту, у вас скорее всего отсутствует сетевой доступ к Sandbox.

Если у вас отсутствует сетевой доступ (при этом вы подключаетесь с IP-адреса сотрудника, а не системы), вы можете самостоятельно инициировать процесс предоставления доступа, следуя инструкции ниже.

Инструкция при ошибке подключения (Отсутствие сетевого доступа)

1. Определите свой IP-адрес в корпоративной сети банка

- a. Зайти на страницу <https://agenapisandbox.moscow.alfaintra.net/>



- b.

2. Проверьте, входит ли ваш IP-адрес в корпоративные подсети банка

- a. Перейдите по ссылке: [Список подсетей Альфа-Банка](#)²⁰.
- b. Убедитесь, что ваш IP-адрес соответствует одной из указанных подсетей.
 - i. Если ваш адрес присутствует — вы находитесь в доверенной сети, и можете продолжить подачу заявки. Заявка подается на всю подсеть
 - ii. Если ваш адрес **отсутствует** в списке — обратитесь в службу поддержки сетевой безопасности по электронной почте: netsec@alfabank.ru²¹ с указанием вашего IP-адреса и места подключения.

19. <https://confluence.moscow.alfaintra.net/spaces/GPT/pages/2364080887/%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F+%D0%BF%D0%BE+%D0%BF%D0%BE%D0%B4%D0%BA%D0%BB%D1%8E%D1%87%D0%B5%D0%BD%D0%B8%D1%8E+%D0%BA+LLM>

20. <https://confluence.moscow.alfaintra.net/pages/viewpage.action?pagelId=628788653>

с. **Подайте заявку на предоставление доступа (форма IT0105)**

- i. Перейдите в систему подачи заявок и создайте новую заявку по форме **IT0105**.
- ii. Заполните следующие поля:
 - 1. **Sources (Источник):** ваша IPv4-подсеть (например, 10.0.0.0/10).
 - 2. **Destinations (Назначение):** 10.229.119.239 (адрес сервера SandBox).
 - 3. Остальные поля в таблице не заполняйте
 - 4. Укажите цель запроса: *«Предоставление доступа к SandBox для выполнения рабочих задач»*.

3. **Проверка подключения** (После обработки заявки и получения уведомления о выполнении)

- a. Попробуйте подключиться к ресурсу SandBox.
- b. Убедитесь, что соединение установлено корректно.
- c. Если:
 - i. Ваш IP-адрес **входит в доверенную подсеть**, заявка **обработана**, но доступ **отсутствует** — обратитесь в техническую поддержку с указанием реквизитов заявки и результатов проверки.
 - ii. Ваш IP-адрес **не указан** в списке подсетей — подача заявки невозможна до уточнения сетевой конфигурации. Обратитесь в netsec@alfabank.ru²² для включения вашей подсети в доверенный перечень.

21. <mailto:netsec@alfabank.ru>

22. <mailto:netsec@alfabank.ru>

11 Если вы столкнулись с некорректной работой Sandbox API

Заводите GPUPROJ с типом Bug ([Link](#)²³), в котором опишите все детали дефекта, логи, приложите curl запроса с messageId и ответа и направляйте их нам на почту aakomissarov@alfabank.ru²⁴ и dakornev@alfabank.ru²⁵. В течение 3-х рабочих дней команда возьмет в анализ баг, локализует проблему.

Описание возможных ошибок

Код ошибки	Описание	Действия при ошибке
400 (Bad Request)	Некорректный запрос	Проверьте параметры запроса
	Одинаковый messageId для разных запросов	Добавьте генерацию уникального messageId для каждого нового запроса
	Превышение количества токенов в запросе	Отправьте запрос на эндпоинт /tokens/count , посчитать количество токенов в сообщении. Отправьте запрос на эндпоинт /models , получить информацию о максимальном допустимом количестве входных токенов для выбранной модели. Если количество токенов в сообщении превышает максимальное количество токенов для модели, необходимо уменьшить сообщение или выбрать модель с большим размером контекстного окна.
403	Неверная роль	Проверьте модель вызова и эндпоинт
404	Неверный эндпоинт	Проверьте вызываемый эндпоинт на предмет синтаксических ошибок
406 (Not Acceptable)	Некорректный systemId	Проверьте настройки

23. <https://jira.moscow.alfaintra.net/secure/CreateIssue!default.jspa>

24. <mailto:aakomissarov@alfabank.ru>

25. <mailto:dakornev@alfabank.ru>

Код ошибки	Описание	Действия при ошибке
413	Превышение размера сообщения	Отправьте запрос на эндпоинт /tokens/count, посчитать количество токенов в сообщении (ВАЖНО - на текущий момент /tokens/count не учитывает контекст в файле. Доработка в процессе). Отправьте запрос на эндпоинт /models, получить информацию о максимальном допустимом количестве входных токенов для выбранной модели. Если количество токенов в сообщении превышает максимальное количество токенов для модели, необходимо уменьшить сообщение или выбрать модель с БОЛЬШИМ размером контекстного окна.
422 (Unprocessable Entity)	Неверный параметр в body. Запрос невозможно отправить в модель. (Для запросов completions и chat/completions)	Проверьте параметры запроса
	Выбрана неверная модель. Модель не поддерживается, либо для модели невозможно произвести подсчет токенов (для метода /tokens/count)	Проверьте актуальность названия модели. Если модель поддерживается, обратиться к команде AlfaGen для добавления возможности подсчета токенов для выбранной модели.
	Не пройдена проверка загружаемого файла - тип, размер, сигнатура (для метода /upload-file)	Проверьте загружаемый файл на удовлетворение критериям загрузки
	Превышение размера сообщения (Max tokens exceed: [Single message exceeds maximum token limit], [messageId=uidun].)	Отправьте запрос на эндпоинт /tokens/count, посчитать количество токенов в сообщении (ВАЖНО - на текущий момент /tokens/count не учитывает контекст в файле. Доработка в процессе). Отправьте запрос на эндпоинт /models, получить информацию о максимальном допустимом количестве входных токенов для выбранной модели. Если количество токенов в сообщении превышает максимальное количество токенов для модели, необходимо уменьшить сообщение или выбрать модель с БОЛЬШИМ размером контекстного окна.
429 (Too Many Requests)	Модель ответила ошибкой.	Проверьте параметры запроса

Код ошибки	Описание	Действия при ошибке
500 (Internal Server Error)	Какой-либо из микросервисов в Альфаген не отвечает. Не обрабатываемое состояние запроса	Обратитесь в чат поддержки AlfaGen Club для разбора ситуации
503 (Service Unavailable)	Вызванная модель не отвечает или возвращает ошибку (любую)	Проверьте параметры запроса
523	Запрос вернулся из модели с ошибкой.	Обратитесь в чат поддержки AlfaGen Club для разбора ситуации
	Не удалось обработать загружаемый файл (для метода /upload-file)	Обратитесь в чат поддержки AlfaGen Club для разбора ситуации



Задать вопросы по работе Sandbox API, рассказать о проблеме или предложить feature request можно в чате AlfaGen Club (внутренний чат "Sandbox API"): [в контуре банка](#)²⁶ и [вне контура](#).²⁷

26. <https://ap.moscow.alfaintra.net/channels/?inviteId=171>

27. <https://alfapeople.alfabank.ru/channels/?inviteId=171>